Texto a SQL con LoRA

Proyecto 3. Deep Learning 2026. Universidad del Valle

GenserDev y Hugo2049

Modelo base: Qwen/Qwen3-1.7B sin modo de razonamiento

Motor: MySQL 8.4.10 con configuracion por defecto

Dataset de entrenamiento

12 esquemas propios con nombres en espanol, ingles y abreviados, todos con COMMENT

Pares generados con plantillas en tres niveles: facil, media y dificil

5400 pares generados y 2630 validos que corren sin error en MySQL 8.4.10

Descartes: 2734 preguntas duplicadas y 36 con resultado vacio

Archivos: datos/entrenamiento.jsonl y datos/descartes.csv

Validacion propia

2 esquemas que no aparecen en el entrenamiento: veterinaria (6 tablas) y airline (5 tablas)

40 preguntas propias: 13 faciles, 15 medias y 12 dificiles

Particion por esquema, no por pregunta

Metrica: exactitud por ejecucion ponderada (pesos 1, 2 y 3)

Orden de filas solo si se pide, numeros a 2 decimales, columnas extra no penalizan

Prompt y solucion.py

El esquema se compacta: se quitan ENGINE, CHARSET, indices y NOT NULL

Se conservan tipos, llaves primarias, llaves foraneas y COMMENT

Generacion determinista con do_sample=False

Con usar_adapter en false se usa el modelo base con el mismo prompt

La salida se limpia para devolver una sola consulta SELECT o WITH

Dos configuraciones de LoRA

Solo cambia el rango r. Lo demas es igual: lr 2e-4, alpha 32, mismos 300 ejemplos

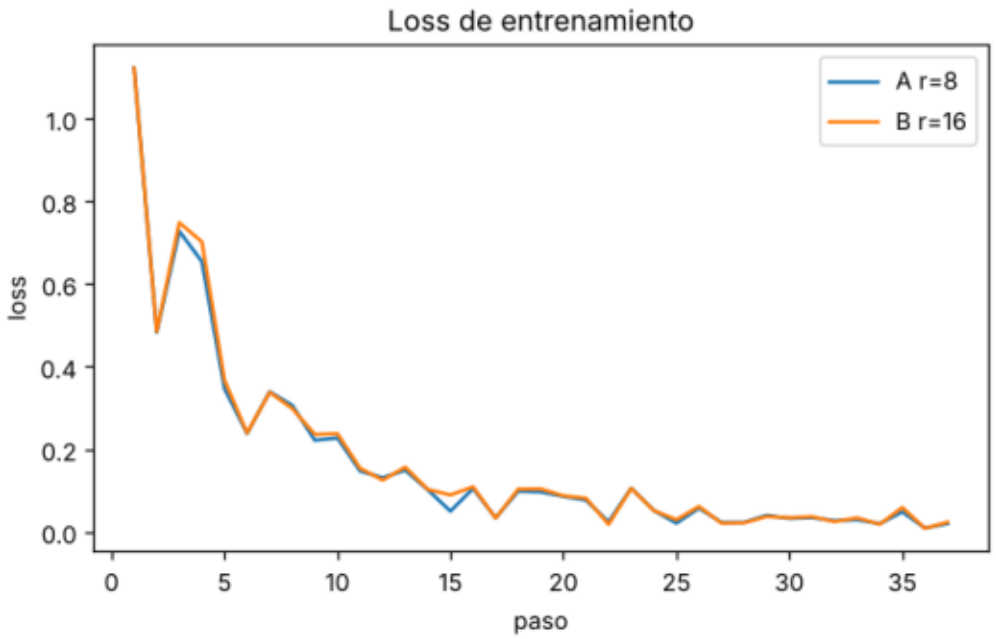
Hipotesis A (r=8): basta para aprender formato y patrones de MySQL

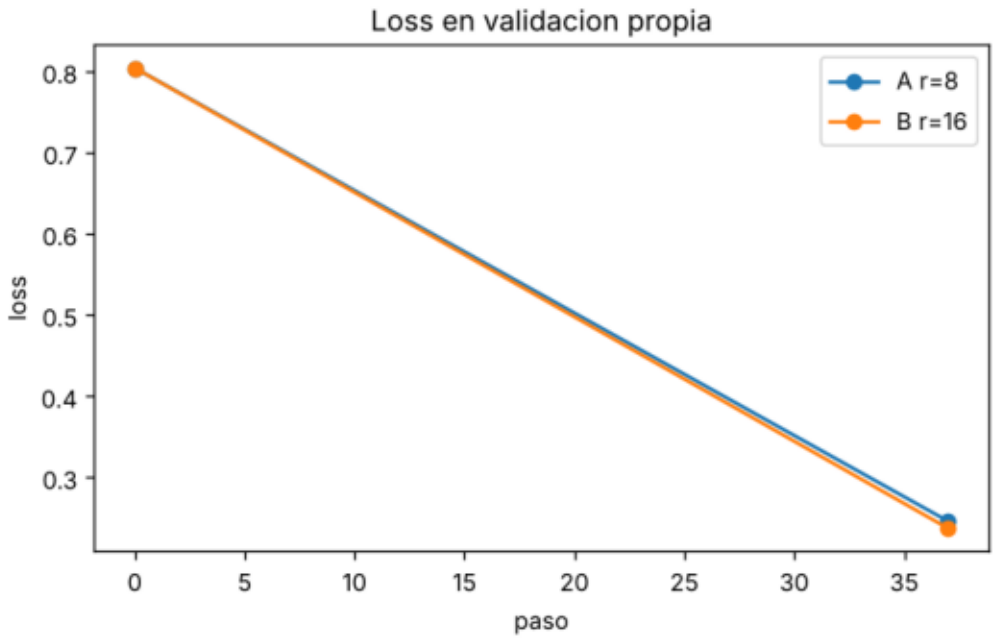
Hipotesis B (r=16): loss algo menor pero sin gran mejora en validacion

Entrenado en CPU con bfloat16, una epoca

config	r	parametros_entrenables	minutos	loss_final	loss_validacion_final
A	8	8716288	53.8	0.0199	0.246
B	16	17432576	41.7	0.0234	0.2372

Curvas de loss

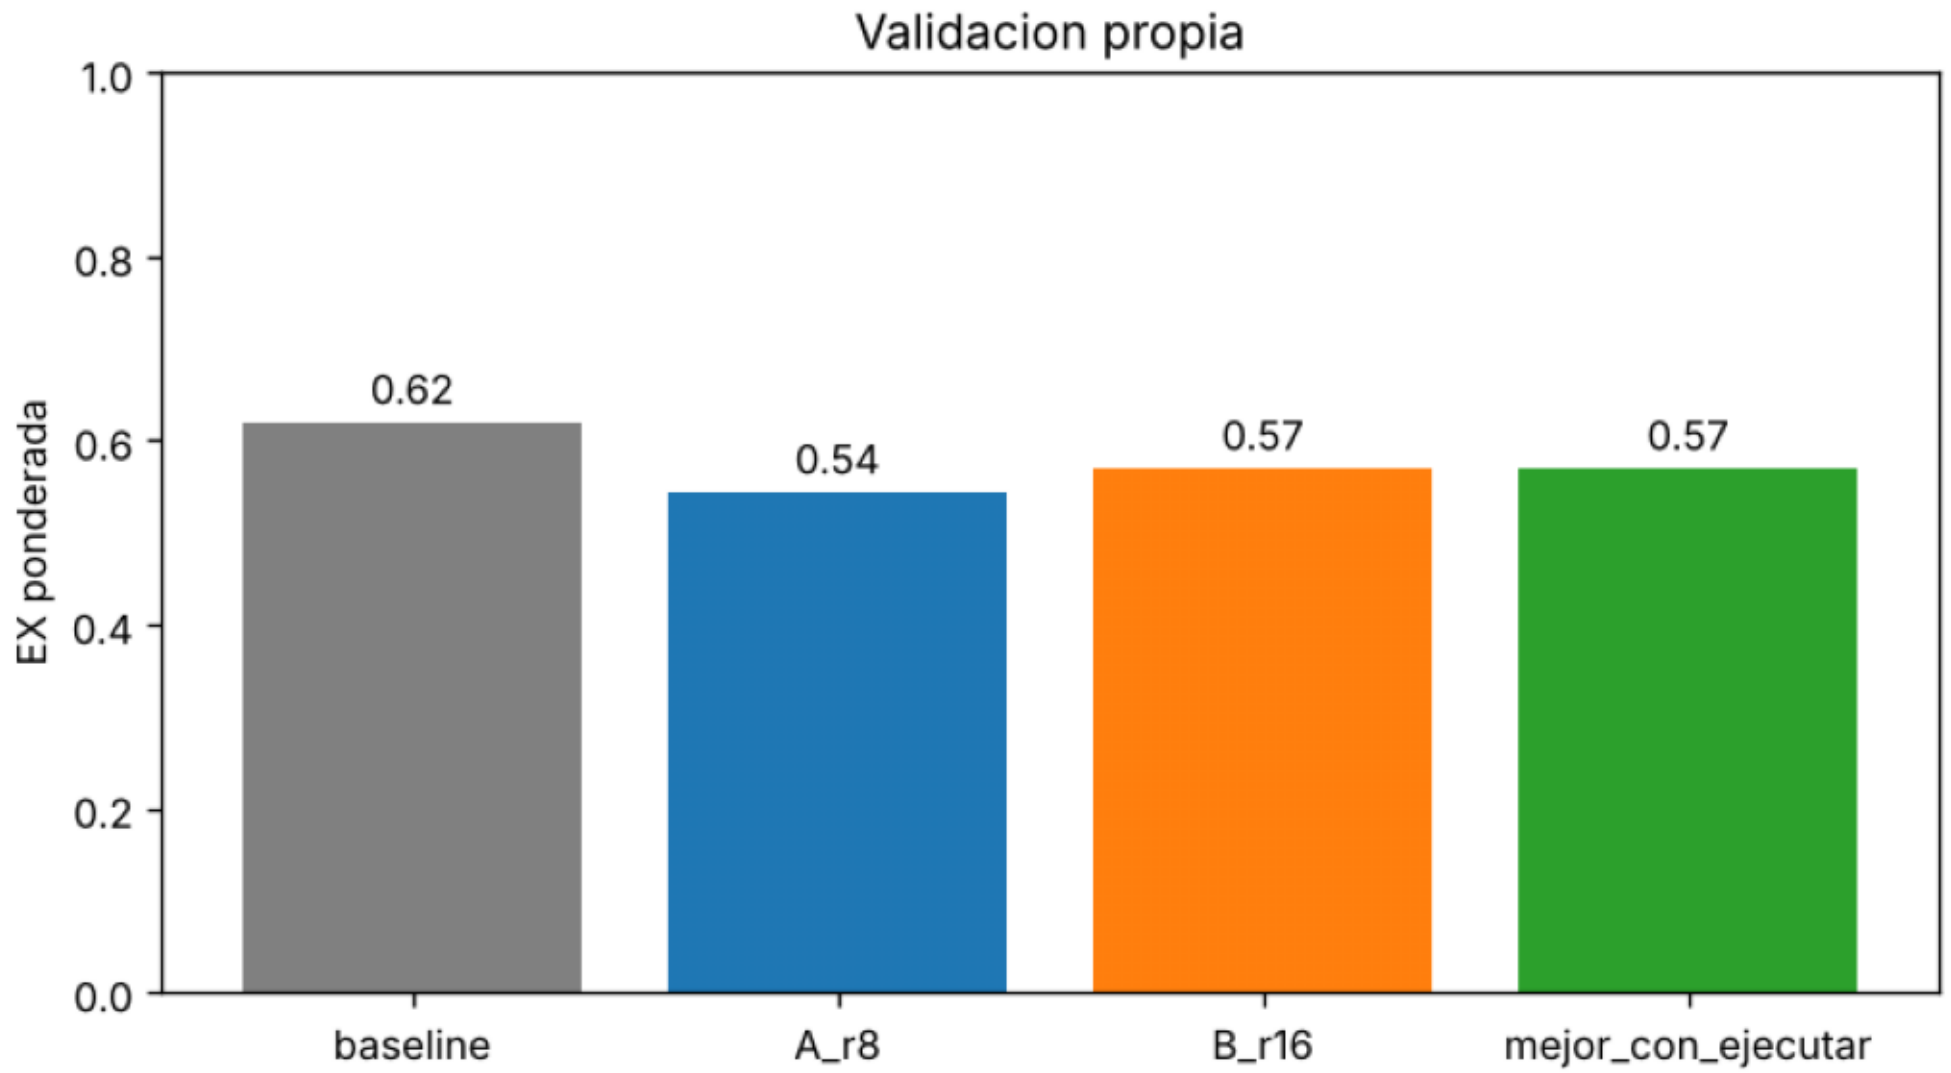




Resultados en validacion propia

corrida	EX	aciertos	facil	media	dificil	segundos_promedio
baseline	0.62	27	11 de 13	10 de 15	6 de 12	8.5
A_r8	0.544	24	11 de 13	7 de 15	6 de 12	10.0
B_r16	0.57	25	11 de 13	8 de 15	6 de 12	10.1
mejor_con_ejecutar	0.57	25	11 de 13	8 de 15	6 de 12	2.7

EX por corrida



Experimento de inferencia

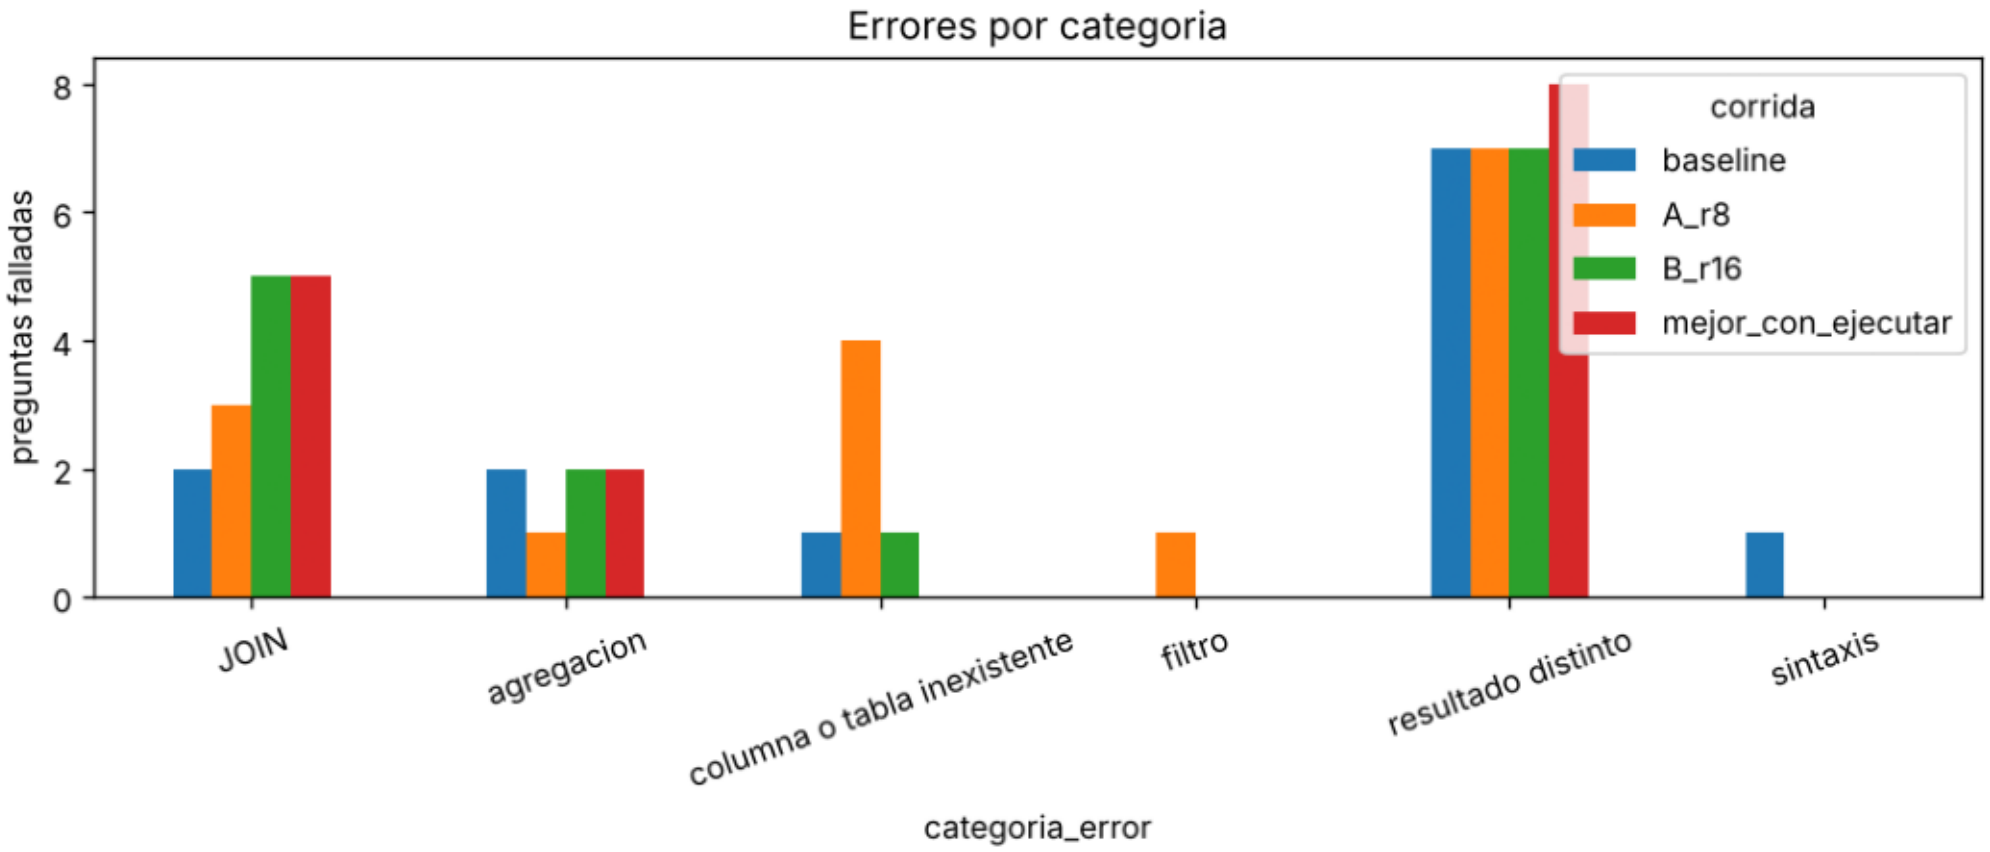
Si MySQL devuelve error, se le muestra el error al modelo y se pide otra consulta

Maximo 3 llamadas a ejecutar por pregunta

Resultado: el EX quedo igual, 0.57 con y sin correccion

Solo ayuda cuando el fallo es un error de ejecucion, no cuando el resultado es distinto

Analisis de errores por categoria



Prediccion de EX en la evaluacion oculta

Prediccion con adapter: EX entre 0.45 y 0.55

Prediccion sin adapter: EX entre 0.50 y 0.60

En validacion propia el base saco 0.62 y el adapter B saco 0.57

La evaluacion oculta tiene mas tablas (5 a 10) y nombres que no vimos, por eso esperamos algo menos

El adapter aprendio a agrupar por la llave primaria, que es el patron de nuestras plantillas

Eso falla cuando la pregunta agrupa por otra columna, y en la evaluacion oculta pasara igual

Por eso no esperamos mejora sobre el modelo base con este adapter

Conclusiones

La loss en validacion bajo de 0.80 a 0.24, pero el EX bajo de 0.62 a 0.57

El adapter copio patrones de las plantillas, como agrupar siempre por la llave primaria

El limite del hardware nos dejo usar solo 300 ejemplos por configuracion en CPU

Siguiente paso: plantillas mas variadas y entrenar en GPU con todo el dataset

Con GPU se puede entrenar con los 2630 pares y mas epocas

Conservamos adapter, prompt, dataset y evaluador para el proyecto final